



CABLEWATCH

batch-72-paris / Data Engineering
9 janvier 2026

Matz Sébastien
Soto Jean Luis
Choisis Rachel

Zoom du les composant logiciels du projet


Quels sont les modules logiciels mise en oeuvre ?

- ici faut faire un schéma
- faire comme si le projet était terminé (on présente une finalité)

Slides: --> [] -->

- ingest [Seb]
- extraction du speech [Jean]
- extraction des bandeaux (rachel)
- pour les extractions présenter les données qu'on obtient dans les tables
- reconstruction/aggregation/mise en forme des document [Seb]
- Service rendu à l'utilisateur, consommation des données (LLM, RAG) [Jean]

Overview



1. `cablewatch` *enregistre le stream* d'une chaîne d'actualité et *analyse la vidéo enregistré pour en extraire des données. Ceci de manière continue.*

2. L'utilisateur via une interface *web* (style *LLM chatbot*) peut poser des questions sur le contenu de la chaîne qui a été analysée.

- Source de donnée



- Plus particulièrement le *stream live* youtube de

franceinfo:

- yt-dlp
 - permet de sauvegarder une vidéo ou un *stream* en local sur le *filesystem*
 - ligne de commande
 - pas un programme officiel
 - authentification préalable en manuel depuis le navigateur
 - pour le déploiement: possibilité de sauvegarder le cookie d'authentification


```
# apt-get install yt-dlp
```

```
$ pip install yt-dlp
```

```
$ yt-dlp https://www.youtube.com/watch?v=ucZl6vQ\_8Uo
```

```
$ ls
```

```
'Audio Video Sync Test [ucZl6vQ_8Uo].webm'
```



- **Components**

- Architecture
- Ingestion
- Extraction Banners
- Speech Extraction
- Document Generator
- RAG

- **Perspectives**




Components

Data Flow & Orchestration



(made with crayon.com)






Extraction

Ingest component


- `yt-dlp` | `ffmpeg`
- enregistrement sous forme de segments (HLS)
- horodatage des segments
- *respawn*
 - coupure journalière du *stream* youtube
 - pas de réseau
 - autre problème...
- ajouter un *marker* en cas de trous (discontinuité)
- API interne pour
 - arrêter / démarrer l'enregistrement - orchestrateur (on ignore les programmes de nuit)
 - parcourir les vidéo enregistrées
 - lancer `ffmpeg` sur un time range





Transformation

Banners Extractor



Composition d'une vidéo d'une chaîne info



Le fil info

titre du programme

Rencontre Zelensky-Trump prévue dimanche en Floride

theme de l'émission

Le fil info

Violeta Moskalu Maîtresse de conférence et fondatrice de Global Ukraine


interlocuteur

Social Plusieurs préfetures du Grand-Est, de Bretagne ou encore de Nouvelle-Aquitaine ont activé le plan "grand froid".

actualités (option)

Banners Extractor - Crop & Freeze image

- Crop la vidéo en fonction des différentes bannières (ffmpeg)
- Analyser lorsque l'image change (freezedetect)
- Enregistrer le tout en format png



Le fil info

```
"name": "program_title",  
"crop": "crop=240:82:977:ih-0",  
"freeze": "freezedetect=n=0.005:d=7",
```


Social Plusieurs préfectures du Grand-Est, de Bretagne ou encore de Nouvelle-Aquitaine ont activé le plan "grand froid".

```
"name": "breaking_news",  
"crop": "crop=909:86:60:ih-0",  
"freeze": "freezedetect=n=0.002:d=3",
```

- Extraire le texte de mes images:
 - convertir mon image en gris et jouer avec le contraste
 - évaluer la qualité de mon image (background color)
 - lancement de l'OCR
 - clean le texte (nettoyer les espaces, les sauts de lignes...)

```
Name File,program_segment_2025-12-26_14h15-35s
banner_type,timestamp_start,timestamp_end,banner_content
speaker,0.0,4.0,_Violeta Moskalu Maîtresse de conférence et fondatrice de Global Ukraine er
program_title,0.0,26.0,Le fil info
topic,0.0,16.0,(Rencontre Zelensky-Trump prévue dimanche en Floride)
breaking_news,0.0,6.0,"Social Plusieurs préfectures du Grand-Est, de Bretagne ou encore de Nouvelle-Aquitai
breaking_news,6.0,10.0,"a D Nouvelle-Aquitaine ont activé le plan "grand froid"", Social Épisode de froid:
breaking_news,10.0,16.0,"Social Épisode de froid: un sans-abri âgé de 35 ans est mort la nuit du réveillon
breaking_news,22.0,26.0,"le. F4 CR: n A Ü 4 PT Santé L'entrée en vigueur du nouveau congé de naissance repo
```

banners_segment_2025-12-26_14h15-35s.csv



Le Défi : Le *Bruit Brut*

Pourquoi agir ?

- **Données brutes** : Les fichiers audio ne sont que des ondes sonores pour une machine.
- **Manque de sens** : Sans traitement, l'ordinateur ne comprend ni le contenu ni le contexte.



La Solution : Machine Learning

Comment transformer le son en données exploitables ?

- **Transcription (Speech-to-Text)** : Convertir les ondes sonores en texte écrit pour analyser le contenu.
- **Diarisation (Speaker Diarization)** : Détecter, regrouper et identifier les voix pour savoir **qui dit quoi**.





Propriétaire

Open Source

Transcription de segment_2025-12-24_16h36mn50

Durée facturée: 31s

Date de transcription: 2025-12-29T20:14:36.585268

Locuteur 0: Cornu.

Locuteur 1: Bonsoir.

Locuteur 2: Jusqu'à 7 million de téléspectateurs suivent cette

Locuteur 0: Qui se présente devant nous ce soir? Est-ce l'ex

Locuteur 1: Bah le premier ministre qui a démissionné, qui a

\$ cablewatch-extract-speech

Trigger


1. Extraction
Sélection de la période

2. Préparation
Conversion en format WAV

3. Découpage
Détection des silences

4. Analyse IA
Envoi à l'API ML

5. Transcription
Texte final horodaté



- Générer sous forme de fichiers `.json`
 - Le programme de la journée (un document / jour) et par émission détailler:
 - liste des intervenants
 - les sujets traités
 - le créneau horaire
 - Le détail par émission (un document / émission)
 - découpage par sujets traités
 - transcription du *speech* par intervenants
 - plages horaires des sujets traités


Exemple du fichier .json pour une émission

*Le challenge ici c'est
l'agrégation des données
présentes dans les tables/.csvs
speech et banners pour faire
le lien entre le bandeau de type
speaker et le speaker-id de
la diarization !*

```
{
  "document-type": "tv-show-details",
  "name": "La matinale",
  "timestamp-begin": "2025-12-26 06h29",
  "timestamp-end": "2025-12-26 07h40",
  "topics": [
    {
      "title": "Vote du budget",
      "speakers": ["Antoine Bueno Essayiste", "...", "..."]
      "speech": [
        {"speaker-id": 0, "words": "bla bla bla", "timestamp": "..."},
        {"speaker-id": 1, "words": "blo blo blo", "timestamp": "..."},
        {"speaker-id": 0, "word": "ah ah ah", "timestamp": "..."},
      ]
    }
  ]
}
```



Chargement




Trop de données

- **Accumulation** : Chaque jour, nous capturons des heures de direct sur France Info.
- **Le Chaos** : Des milliers de pages de texte où il est impossible de retrouver une info précise.



Base de données *intelligente*

- **Structuration** : On transforme les textes en *Vecteurs* que la machine comprend.
- **Requête (Query)** : L'utilisateur pose une question en langage naturel (ex: "Quels étaient les invités de la matinale ?")






LightRag (Open Source)



Quelle stratégie RAG pour répondre à quoi?

- **Dépendances & Séries:**
 - Quel invité est passé juste après le flash info de 8h ?
- **Binaire:**
 - Est-ce que le sujet 'IA' a été abordé ce matin ?
- **Recherche exacte:**
 - Retrouve tous les passages où le mot 'Antarctique' est cité.
- **Fuzzy:**
 - Cherche des témoignages sur la difficulté de se loger
- **Résumé:**
 - Fais-moi un résumé des principaux points abordés durant la matinale

Système de recherche intelligente qui combine des **graphes de connaissances** et une **recherche à double niveau**





Ok ...
mais ça donne quoi ?



- Les parties majeurs sont faites:
 - ingest
 - extract banners
 - speech extractor
- Création d'un orchestrateur minimaliste



- Les parties majeurs sont faites:
 - ✓ ingest
 - ✓ extract banners
 - ✓ speech extractor
- Création d'un orchestrateur minimaliste 



- Un liant qui relie le tout : une base de données
- Un orchestrateur (pour le batch)
- Un site web où l'utilisateur pourra interroger le LLM



Un liant qui relie le tout : une **base de données**



Un **orchestrateur**
(pour le batch)



Un **site web** où
l'utilisateur pourra
interroger le LLM




- Avoir une bonne organisation malgré le temps imparti sur le projet et le mode *remote*
- Comprendre et prendre en main le projet avec un format vidéo (extraction vidéo, extraction texte, extraction audio)
- L'infrastructure est *challenging*



Avoir une bonne **organisation** malgré le temps imparti sur le projet et le mode **remote**



Comprendre et prendre en main le projet avec un format vidéo (extraction vidéo, extraction texte, extraction audio)



L'infrastructure est **challenging**



Merci!